

Sponser Analítica

Pipeline de datos, pronóstico de demanda y reabastecimiento productivizados para un distribuidor de nutrición deportiva

Trabajo Fin de Máster	Máster Data Science, Big Data & Business Analytics 2025-2026 (Semi-presencial)
Universidad	Universidad Complutense de Madrid (UCM), Instituto NTIC
Autor	Joseph Alejandro Mora Murillo
Tutores	Carlos Ortega, Santiago Mota
Repositorio	https://github.com/0107joseph-ui/sponser-analitica-tfm (privado, tutores con acceso)

Índice

1. Resumen ejecutivo
2. Contexto y objetivos de negocio
3. Fuente de datos y gobernanza
4. Arquitectura de la solución
5. Pipeline de datos (ETL)
6. Análisis exploratorio de datos
7. Modelado predictivo de demanda
8. Reabastecimiento: de la predicción a la decisión de compra
9. Productivización: la aplicación web
10. Discusión: interpretabilidad y limitaciones
11. Conclusiones y trabajo futuro
12. Bibliografía y referencias

Anexo (no cuenta para el límite de extensión): código fuente completo, y documentación técnica ampliada en `docs/arquitectura.md`, `docs/pipeline_datos.md` y `docs/modelado.md` del repositorio.

1. Resumen ejecutivo

Sponser Costa Rica es un distribuidor de nutrición deportiva con un catálogo de cerca de 170 SKUs y una cartera de 194 clientes activos. La operación dependía de reportes planos exportados a mano, sin un pronóstico de demanda que anticipara estacionalidad o eventos, y sin visibilidad sistemática del riesgo de que el inventario existente venza antes de poder venderse.

Este trabajo desarrolla, sobre datos reales de la empresa (ventas 2023-2026, inventario por lote con fecha de vencimiento, patrocinios), una solución de extremo a extremo: un pipeline de datos que limpia y agrega la información comercial, un modelo de pronóstico de demanda diaria por producto (LightGBM, arquitectura de dos etapas), una simulación de reabastecimiento consciente de vencimientos (FIFO), y una aplicación web donde el equipo comercial carga los datos actualizados, corre el modelo y analiza los resultados. Esto cumple el criterio de productivización de un modelo predictivo: recibe datos nuevos y devuelve una recomendación de compra lista para usar.

Cifras clave: 10.929 líneas de venta reales (abr. 2023 – may. 2026) · 194 clientes · ~170 SKUs · modelo con AUC de clasificación 0.90 y 93.4% de precisión agregada de volumen contra el backtest · 23% de los clientes concentran el 80% de la facturación.

2. Contexto y objetivos de negocio

La operación comercial de Sponser identificó tres problemas concretos que motivan este trabajo:

- **Falta de visibilidad consolidada:** ventas, clientes y patrocinios se revisaban en reportes planos exportados del sistema de facturación, sin agregación ni tendencia visible.
- **Reposición de inventario a criterio,** sin un pronóstico de demanda que distinguiera estacionalidad, eventos deportivos o inactividad de producto del ruido normal de la venta diaria.
- **Riesgo de vencimiento:** con inventario organizado por lotes con fecha de caducidad, no había forma sistemática de saber qué unidades, al ritmo de venta real, no se iban a consumir antes de vencer.

El objetivo del proyecto es doble: (a) demostrar un desarrollo analítico completo (descriptivo, predictivo y de decisión) sobre un problema de negocio real, y (b) entregar una herramienta que el equipo comercial de Sponser use de forma continua, no un análisis de una sola vez.

3. Fuente de datos y gobernanza

Los datos utilizados son reales y propiedad de Sponser Costa Rica, incluidos en este trabajo con autorización de la empresa para fines exclusivamente académicos (ver `LICENSE.md` del repositorio). No es un dataset público ni sintético: son los reportes de venta e inventario que la empresa exporta de su propio sistema de facturación.

Fuente	Contenido	Volumen
COM / Control Sponser (.xls)	Detalle de facturación por línea	10.929 filas · 3.071 facturas
Inventario (.xlsx)	Lotes con fecha de vencimiento	112 lotes activos
Rango temporal	—	29 abr. 2023 – 28 may. 2026
Clientes	—	194
Productos (SKUs)	—	~170

Diccionario de datos completo (columnas de cada tabla procesada) en el README del repositorio, sección "Diccionario de datos".

4. Arquitectura de la solución

La solución se divide en dos componentes independientes que se comunican solo a través de archivos y ejecución de subprocesos, nunca por importación de código. Así, el pipeline de datos y el backend pueden evolucionar sin arriesgarse mutuamente:

- **Pipeline de datos y modelado** (Python + pandas + LightGBM): extracción, transformación, entrenamiento del modelo, generación del pronóstico y cálculo de la recomendación de compra.
- **Backend + dashboard** (FastAPI + SQLAlchemy + frontend web): sirve los resultados del pipeline vía API, gestiona usuarios/roles, y permite disparar el pipeline desde la interfaz cuando llegan datos nuevos.

Diagrama de arquitectura y justificación detallada de cada decisión de diseño (capas de caché, seguridad, aislamiento entre componentes) en `docs/arquitectura.md`.

5. Pipeline de datos (ETL)

El pipeline resuelve tres retos particulares de los datos crudos de Sponser, antes de que cualquier análisis o modelo pueda usarlos:

5.1 Extracción

Los reportes de venta no son archivos Excel binarios: son una tabla HTML (GridView de ASP.NET) exportada con extensión `.xls`. Se parsean con la librería estándar de Python (`html.parser`), identificando cada archivo por su nombre para etiquetar la fuente (COM/Control) y el año.

5.2 Transformación

Se normaliza la moneda (un 0.04% de las filas viene en colones y se convierte a USD), se separan las salidas de inventario por patrocinio deportivo del resto de la venta comercial (no son venta orgánica y sesgarían el modelo si se incluyeran), y se calcula la venta neta restando el IVA del monto bruto facturado. Esto último se verificó empíricamente contra ambas fuentes de reporte, con 99.9% de coincidencia con la identidad contable esperada.

5.3 Carga

Las tablas resultantes (ventas diarias por producto, RFM de clientes, inventario por lote, patrocinios) se escriben como CSV, consumibles tanto por el modelo como por el backend sin conocer la lógica previa de extracción.

Detalle completo de cada transformación, con la lógica exacta de separación de patrocinios y conversión de moneda, en `docs/pipeline_datos.md`.

6. Análisis exploratorio de datos

La facturación mensual muestra una tendencia de crecimiento sostenida sobre los tres años de historia disponibles, con una estacionalidad marcada (picos y valles que se repiten en el mismo período del año), consistente con una demanda ligada a temporadas deportivas y patrocinios de eventos:




Figura 1. Facturación mensual de ventas orgánicas (excluye patrocinios), abril 2023 a mayo 2026.

La facturación está fuertemente concentrada en un núcleo de productos: 15 SKUs explican una porción desproporcionada de la venta total, lo que justifica priorizar el esfuerzo de pronóstico y reabastecimiento en ese subconjunto sin descuidar el resto del catálogo:




Figura 2. Los 15 SKUs de mayor facturación acumulada.

Lo mismo ocurre del lado de clientes: el **23% de la cartera concentra el 80% de la facturación**, un patrón de Pareto clásico que tiene implicaciones directas de negocio (priorización de cuentas clave, gestión de riesgo de concentración):




Figura 3. Curva de concentración de clientes por facturación acumulada.

Del lado de inventario, la distribución de lotes por meses restantes hasta vencer muestra que una porción del stock actual tiene una ventana de venta relativamente corta. Esa es la motivación directa del componente de reabastecimiento que prioriza la salida del inventario más próximo a vencer (sección 8):




Figura 4. Distribución de lotes de inventario según meses restantes hasta la fecha de vencimiento.

7. Modelado predictivo de demanda

7.1 Por qué un modelo de dos etapas ("hurdle")

El panel producto × día es mayormente ceros: en el conjunto de validación de la versión vigente del modelo, solo el 5.7% de las combinaciones producto-día tuvieron venta real. Un único regresor entrenado directamente sobre esto tiende a "aprender a predecir cero" y subestimar los días en que sí hay demanda. Las primeras versiones del proyecto (v1-v4) usaron un solo LightGBM con objetivo Tweedie (pensado para variables con exceso de ceros); a partir de v5 se cambió a una arquitectura de dos etapas:

1. **Clasificación:** ¿hay venta ese producto ese día? (LightGBM binario, AUC = 0.90 en la versión vigente).
2. **Regresión:** dado que sí hay venta, ¿cuánto se vende? (LightGBM con objetivo Poisson, entrenado solo sobre filas con venta positiva).

La predicción final combina ambas: $E[\text{demanda}] = P(\text{venta}) \times E[\text{cantidad} \mid \text{venta}]$. Cada etapa aprende una sola pregunta en vez de las dos a la vez.

7.2 Variables (features)

Calendario (día del mes, semana del año, trimestre, fin de semana), eventos (días hasta/desde el evento más cercano), rezagos (1, 2, 3, 7, 14 y 28 días), medias y desviación móvil (7/28/90 días), e histórico promedio del producto. En total, 21 variables.

7.3 Validación y resultados

Split temporal (los últimos 150 días como validación, nunca aleatorio, para no filtrar información del futuro), y un backtest recursivo (el mismo procedimiento que usaría el modelo en producción) contra ventas ya ocurridas pero excluidas del entrenamiento:




Figura 5. Backtest de la versión vigente (v8): unidades reales vs. pronosticadas, agregado mensual de todos los SKUs.

Métrica	Valor (v8)	Lectura de negocio
AUC de clasificación	0.90	Distingue bien los días con venta de los días sin venta
% del volumen total real (backtest)	93.4%	El volumen agregado pronosticado a 150 días se acerca mucho al real
% de combinaciones SKU-mes dentro de $\pm 20\%$	24.2%	Precisión a nivel granular, más exigente que el agregado

Se entrenaron y compararon 8 versiones del modelo durante el desarrollo, documentadas con sus métricas completas en el repositorio. La versión v8 mejora notablemente el error absoluto medio sobre las versiones anteriores, sin sacrificar la precisión agregada de volumen.

Tabla comparativa completa de las 8 versiones, metodología de features y discusión de por qué el WMAPE a nivel de fila es alto pese a que las métricas agregadas son buenas (naturaleza intermitente de la demanda), en `docs/modelado.md`.

8. Reabastecimiento: de la predicción a la decisión de compra

El pronóstico por sí solo no genera una decisión de compra: hace falta cruzarlo con el inventario existente (por lote, con su fecha de vencimiento), el lead time de fábrica, el stock de seguridad, y las restricciones reales de compra (cantidad mínima de pedido y múltiplo de empaque).

El componente de reabastecimiento simula el consumo del inventario existente en orden estricto de vencimiento (FIFO: lo que vence primero se consume primero) contra la **curva día a día** del pronóstico del modelo, no un promedio aplanado, para no perder la estacionalidad que el modelo sí calculó. Solo sugiere pedir la demanda que el inventario actual, más lo ya negociado con el proveedor, no alcanza a cubrir dentro del horizonte de compra.

Con los datos actuales, el modelo identifica ~495 unidades en riesgo real de vencer antes de consumirse al ritmo de venta pronosticado, y recomienda pedir 3.097 unidades adicionales entre los 91 SKUs (de 167) donde el inventario y lo ya comprometido no cubren la demanda esperada.

Detalle del algoritmo FIFO, la construcción del horizonte de simulación y la asignación de ofertas de proveedor, en `docs/arquitectura.md` y el código en `sponser_etl/replenishment/`.

9. Productivización: la aplicación web

Más allá del análisis, el proyecto se entrega como una aplicación en producción que el equipo comercial usa de forma continua. Esto cumple el criterio de que el modelo "reciba datos nuevos y devuelva una predicción" en un contexto real de negocio, no solo como notebook de análisis:

- **Carga de datos:** el equipo comercial sube los archivos de ventas/inventario actualizados directamente desde el navegador; el sistema valida el formato y dispara el pipeline completo (ETL + modelo + reabastecimiento) con un clic.
- **Dashboard interactivo:** KPIs de facturación vs. meta, catálogo con tendencia y riesgo de vencimiento, análisis comercial (ranking de clientes, Pareto, líneas comerciales), proyección por SKU, y pedido a fábrica con la recomendación ya calculada.
- **Seguridad y control de acceso:** autenticación por correo y contraseña con bloqueo tras intentos fallidos, y roles diferenciados (administrador vs. solo lectura) aplicados tanto en la interfaz como en cada endpoint del backend.
- **Gestión de colaboradores:** un administrador puede invitar a otros usuarios del equipo sin intervención técnica.

Capturas de pantalla, credenciales de acceso e instrucciones completas de instalación local en el README del repositorio.

10. Discusión: interpretabilidad y limitaciones

10.1 Interpretabilidad

Ambas etapas del modelo se auditaron por importancia de variable (ganancia de información acumulada en LightGBM). En la etapa de clasificación, el código de producto, la media móvil a 28 días y si el día es fin de semana son las variables más influyentes; en la de regresión, el código de producto y el rezago de 1 día dominan. Son resultados consistentes con la intuición de negocio: cada producto tiene su propio nivel base de demanda, y la venta reciente es el mejor predictor de la venta inmediata siguiente.

10.2 Limitaciones

- El error a nivel de fila individual (SKU-día) es alto por la naturaleza intermitente de la demanda (94% de días sin venta); las métricas agregadas (volumen total, SKU-mes) son las relevantes para la decisión de compra, no el pronóstico diario aislado.
- SKUs nuevos o con poca historia dependen más del promedio general del catálogo que de un patrón propio aprendido.
- El calendario de eventos deportivos que alimenta al modelo se mantiene manualmente y hoy tiene cobertura limitada. Su exactitud acota directamente cuánto puede aprender el modelo sobre el efecto de eventos en la demanda.
- La base de datos operativa (SQLite) es apropiada para el volumen actual de usuarios concurrentes; un despliegue con más usuarios simultáneos se beneficiaría de migrar a PostgreSQL.

11. Conclusiones y trabajo futuro

El proyecto demuestra que es posible pasar de reportes planos sin pronóstico a una herramienta productiva de decisión de compra, construida enteramente sobre datos reales de la empresa: un pipeline reproducible, un modelo de pronóstico con precisión agregada de negocio del 93.4% y una aplicación que el equipo comercial ya puede operar sin intervención técnica.

El mayor impacto de negocio identificado no es el pronóstico en sí, sino la combinación de pronóstico, inventario por lote y vencimiento: es lo que convierte una predicción estadística en una recomendación de compra concreta, con el riesgo de pérdida por vencimiento a la vista desde antes de que ocurra, no después.

Líneas de trabajo futuro:

- Poblar el calendario de eventos con datos reales (hoy es en su mayoría un ejemplo) para capturar mejor los picos de demanda ligados a carreras y promociones.
- Incorporar ofertas de proveedor reales al componente de reabastecimiento (`ofertas\_proveedor.csv` está vacío en el estado actual).
- Migrar la persistencia a PostgreSQL y el despliegue a un entorno cloud gestionado (Cloud Run + Cloud Storage), diseño ya evaluado pero pendiente de la infraestructura del cliente.
- Explorar técnicas de interpretabilidad más profundas (valores SHAP) más allá de la importancia de variable por ganancia.

12. Bibliografía y referencias

- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*. Advances in Neural Information Processing Systems (NeurIPS) 30.
- Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830.
- McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference.
- Croston, J. D. (1972). *Forecasting and Stock Control for Intermittent Demands*. Operational Research Quarterly, 23(3), 289-303. Referencia clásica sobre pronóstico de demanda intermitente, el mismo problema que motiva la arquitectura de dos etapas usada en este trabajo.
- Silver, E. A., Pyke, D. F., & Thomas, D. J. (2016). *Inventory and Production Management in Supply Chains* (4th ed.). CRC Press. Referencia general sobre lead time, stock de seguridad y políticas de reabastecimiento.
- FastAPI. Documentación oficial. <https://fastapi.tiangolo.com/> (consultado en 2026).

Nota: completar/ampliar esta bibliografía con las referencias específicas de los módulos del máster que respalden las decisiones metodológicas (arquitectura hurdle, validación temporal, gradient boosting) según el criterio del alumno.